


# TP558 - Tópicos avançados em Machine Learning:

*Detecção de Anomalias em Imagens MRI  
Cerebrais Utilizando Autoencoders  
Convolucionais*



# Introdução

- Nos últimos anos, a área de *análise de imagens médicas* tem se beneficiado enormemente dos avanços em aprendizado de máquina e inteligência artificial.
- Ferramentas avançadas de IA têm a capacidade de auxiliar médicos e radiologistas na detecção precoce e precisa de diversas condições de saúde.



# Introdução

## Importância da Detecção Automatizada de Anomalias em Imagens Médicas

- A detecção automatizada de anomalias pode melhorar significativamente a precisão dos diagnósticos médicos.
- Reduz o tempo necessário para analisar grandes volumes de dados de imagem, aumentando a eficiência dos profissionais de saúde.



# Introdução

## **Deteção Precoce**

- Identificação precoce de anomalias pode levar a intervenções mais rápidas e tratamentos mais eficazes.
- Pode ser crucial em doenças onde o tempo é um fator crítico, como cânceres e outras condições neurológicas.

# Introdução

## Objetivo do Projeto

- Desenvolver um Modelo de Detecção de Anomalias em imagens médicas:
- *Criar um modelo de autoencoder baseado na arquitetura VGG16 para detectar anomalias em imagens de ressonância magnética (MRI) do cérebro.*
- *Utilizar técnicas de aprendizado profundo para treinar o modelo com dados de MRI, visando uma reconstrução precisa de imagens normais e identificação de anomalias através do erro de reconstrução.*

# Motivação

- *Necessidade de diagnósticos rápidos e precisos em ambientes clínicos.*
- *Limitações de recursos médicos, especialmente em áreas remotas.*
- *Potencial de modelos de aprendizado profundo para transformar a prática médica.*



# Trabalhos Relacionados

Smith e Nichols (2020) discutem os desafios estatísticos no processamento de grandes volumes de dados de neuroimagem, destacando a importância de técnicas automatizadas para análise eficiente [1].

Litjens et al. (2017) apresentam uma revisão abrangente sobre o uso de deep learning em imagens médicas, enfatizando a precisão e a capacidade dessas técnicas para superar métodos tradicionais [2].

Bengio, Courville, e Vincent (2013) exploram o conceito de aprendizado de representação, crucial para o desenvolvimento de modelos que capturam características relevantes de dados complexos, como imagens de MRI [3].

Cheng et al. (2016) apresentam um método aprimorado para classificação de tumores cerebrais utilizando aumento de regiões de tumor e técnicas de partição, melhorando a precisão do diagnóstico [8].

# Metodologia

## **1. Coleta de Dados**

Utilização do dataset "Brain MRI Images for Brain Tumor Detection" do Kaggle. Divisão dos dados em conjuntos de treinamento e teste.


## **2. Pré-processamento dos Dados**

Redimensionamento das imagens para 128x128 pixels. Conversão das imagens para escala de cinza e normalização dos valores de pixel para o intervalo  $[0, 1]$ .



# Metodologia

## 1. Arquitetura do Modelo



- **Encoder:** Utilização das camadas convolucionais da VGG16 pré-treinada.
- **Decoder:** Adição de camadas de convolução transposta e upsampling para reconstruir as imagens.
- *Congelamento das camadas do encoder durante o treinamento para preservar os pesos pré-treinados.*

# Metodologia

## 4. Treinamento

- Treinamento do autoencoder com imagens normais, otimizando a função de perda de erro absoluto médio.

```
3/3 [=====] - 33s 11s/step - loss: 0.0579 - val_loss: 0.0912  
Epoch 99/100  
3/3 [=====] - 31s 10s/step - loss: 0.0578 - val_loss: 0.0905  
Epoch 100/100  
3/3 [=====] - 37s 13s/step - loss: 0.0577 - val_loss: 0.0889
```

## 5. Detecção de Anomalias


- Cálculo do erro de reconstrução das imagens de teste. Definição de um limiar baseado no percentil 95 do erro de reconstrução para classificar imagens como normais ou anômalas.

# Metodologia


## **4. Avaliação e Visualização**

- Visualização das imagens originais, reconstruídas e dos erros de reconstrução.
- Avaliação do modelo Através da curva de aprendizado.

# Resultados



# Resultados



# Comentários finais

## **Eficácia do Modelo:**

- O autoencoder baseado na VGG16 demonstrou ser eficaz na detecção de anomalias em imagens de ressonância magnética (MRI) do cérebro.
- A utilização de camadas convolucionais pré-treinadas permitiu a extração eficiente de características relevantes das imagens.

# Comentários Finais

## **Direções para Trabalhos Futuros:**

- Explorar o uso de outras arquiteturas pré-treinadas para melhorar ainda mais a precisão do modelo.
- Implementar a detecção automatizada de anomalias em sistemas clínicos para suporte ao diagnóstico em tempo real.
- Ampliar o conjunto de dados utilizado para incluir uma maior variedade de anomalias e validar a robustez do modelo.

# Referências

- [1]S. M. Smith and T. E. Nichols, “Statistical challenges in ‘big data’ human neuroimaging,” *Neuron*, vol. 97, no. 2, pp. 263-268, 2020.
- [2]G. Litjens, T. Kooi, B. E. Bejnordi, A. A. A. Setio, F. Ciompi, M. Ghafoorian, et al., “A survey on deep learning in medical image analysis,” *Medical Image Analysis*, vol. 42, pp. 60-88, 2017.
- [3]Y. Bengio, A. Courville, and P. Vincent, “Representation learning: A review and new perspectives,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, no. 8, pp. 1798-1828, 2013.
- [4]Z. Zhou, M. M. R. Siddiquee, N. Tajbakhsh, and J. Liang, “Unet++: A nested u-net architecture for medical image segmentation,” *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, pp. 3-11, 2017.
- [5]C. Baur, B. Wiestler, S. Albarqouni, and N. Navab, “Deep autoencoding models for unsupervised anomaly segmentation in brain MR images,” *International MICCAI Brainlesion Workshop*, pp. 161-169, 2019.
- [6]X. Chen, E. Konukoglu, B. Glocker, and D. Rueckert, “Generative adversarial networks for multi-modality image registration,” *IEEE Transactions on Medical Imaging*, vol. 37, no. 1, pp. 134-146, 2018.
- [7]H. Salehinejad, S. Sankar, J. Barfett, E. Colak, and S. Valaee, “Recent advances in recurrent neural networks,” *arXiv preprint arXiv:1801.01078*, 2018.
- [8]J. Cheng, W. Huang, S. Cao, R. Yang, W. Yang, Z. Yun, et al., “Enhanced performance of brain tumor classification via tumor region augmentation and partition,” *PloS one*, vol. 10, no. 10, e0140381, 2016.



# Link para acessar o código

<https://colab.research.google.com/drive/11SpxdvU369A1wWFN3UoW6HRfzADzdMdq?usp=sharing>.

Obrigado!