


TP558 - Tópicos avançados em Machine Learning:

*Detecção de Anomalias em Imagens MRI
Cerebrais Utilizando Autoencoders
Convolucionais*



Introdução

- os últimos anos, a área de *análise de imagens médicas* tem se beneficiado enormemente dos avanços em aprendizado de máquina e inteligência artificial.
- Ferramentas avançadas de IA têm a capacidade de auxiliar médicos e radiologistas na detecção precoce e precisa de diversas condições de saúde.



Introdução

Importância da Detecção Automatizada de Anomalias em Imagens Médicas

- A detecção automatizada de anomalias pode melhorar significativamente a precisão dos diagnósticos médicos.
- Reduz o tempo necessário para analisar grandes volumes de dados de imagem, aumentando a eficiência dos profissionais de saúde.



Introdução

Deteção Precoce

- Identificação precoce de anomalias pode levar a intervenções mais rápidas e tratamentos mais eficazes.
- Pode ser crucial em doenças onde o tempo é um fator crítico, como cânceres e outras condições neurológicas.

Introdução

Objetivo do Projeto

- Desenvolver um Modelo de Detecção de Anomalias em imagens médicas:
- *Criar um modelo de autoencoder baseado na arquitetura VGG16 para detectar anomalias em imagens de ressonância magnética (MRI) do cérebro.*
- *Utilizar técnicas de aprendizado profundo para treinar o modelo com dados de MRI, visando uma reconstrução precisa de imagens normais e identificação de anomalias através do erro de reconstrução.*

Motivação

- *Necessidade de diagnósticos rápidos e precisos em ambientes clínicos.*
- *Limitações de recursos médicos, especialmente em áreas remotas.*
- *Potencial de modelos de aprendizado profundo para transformar a prática médica.*



Trabalhos Relacionados

Smith e Nichols (2020) discutem os desafios estatísticos no processamento de grandes volumes de dados de neuroimagem, destacando a importância de técnicas automatizadas para análise eficiente [1].

Litjens et al. (2017) apresentam uma revisão abrangente sobre o uso de deep learning em imagens médicas, enfatizando a precisão e a capacidade dessas técnicas para superar métodos tradicionais [2].

Bengio, Courville, e Vincent (2013) exploram o conceito de aprendizado de representação, crucial para o desenvolvimento de modelos que capturam características relevantes de dados complexos, como imagens de MRI [3].

Cheng et al. (2016) apresentam um método aprimorado para classificação de tumores cerebrais utilizando aumento de regiões de tumor e técnicas de partição, melhorando a precisão do diagnóstico [8].

Metodologia

1. Coleta de Dados


Utilização do dataset "Brain MRI Images for Brain Tumor Detection" do Kaggle. Divisão dos dados em conjuntos de treinamento e teste.

2. Pré-processamento dos Dados

Redimensionamento das imagens para 128x128 pixels. Conversão das imagens para escala de cinza e normalização dos valores de pixel para o intervalo $[0, 1]$.

Metodologia

1. Arquitetura do Modelo



- **Encoder:** Utilização das camadas convolucionais da VGG16 pré-treinada.
- **Decoder:** Adição de camadas de convolução transposta e upsampling para reconstruir as imagens.
- *Congelamento das camadas do encoder durante o treinamento para preservar os pesos pré-treinados.*

Metodologia

4. Treinamento

- Treinamento do autoencoder com imagens normais, otimizando a função de perda de erro absoluto médio.

```
3/3 [=====] - 33s 11s/step - loss: 0.0579 - val_loss: 0.0912  
Epoch 99/100  
3/3 [=====] - 31s 10s/step - loss: 0.0578 - val_loss: 0.0905  
Epoch 100/100  
3/3 [=====] - 37s 13s/step - loss: 0.0577 - val_loss: 0.0889
```

5. Detecção de Anomalias


- Cálculo do erro de reconstrução das imagens de teste. Definição de um limiar baseado no percentil 95 do erro de reconstrução para classificar imagens como normais ou anômalas.

Metodologia


4. Avaliação e Visualização

- Visualização das imagens originais, reconstruídas e dos erros de reconstrução.
- Avaliação do modelo Através da curva de aprendizado.

Resultados



Resultados



Comentários finais

Eficácia do Modelo:

- O autoencoder baseado na VGG16 demonstrou ser eficaz na detecção de anomalias em imagens de ressonância magnética (MRI) do cérebro.
- A utilização de camadas convolucionais pré-treinadas permitiu a extração eficiente de características relevantes das imagens.

Comentários Finais

Direções para Trabalhos Futuros:

- Explorar o uso de outras arquiteturas pré-treinadas para melhorar ainda mais a precisão do modelo.
- Implementar a detecção automatizada de anomalias em sistemas clínicos para suporte ao diagnóstico em tempo real.
- Ampliar o conjunto de dados utilizado para incluir uma maior variedade de anomalias e validar a robustez do modelo.

<https://colab.research.google.com/drive/11SpxdvU369A1wWFN3UoW6HRfzADzdMdq?usp=sharing>

Referências

- [1]S. M. Smith and T. E. Nichols, “Statistical challenges in ‘big data’ human neuroimaging,” *Neuron*, vol. 97, no. 2, pp. 263-268, 2020.
- [2]G. Litjens, T. Kooi, B. E. Bejnordi, A. A. A. Setio, F. Ciompi, M. Ghafoorian, et al., “A survey on deep learning in medical image analysis,” *Medical Image Analysis*, vol. 42, pp. 60-88, 2017.
- [3]Y. Bengio, A. Courville, and P. Vincent, “Representation learning: A review and new perspectives,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, no. 8, pp. 1798-1828, 2013.
- [4]Z. Zhou, M. M. R. Siddiquee, N. Tajbakhsh, and J. Liang, “Unet++: A nested u-net architecture for medical image segmentation,” *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, pp. 3-11, 2017.
- [5]C. Baur, B. Wiestler, S. Albarqouni, and N. Navab, “Deep autoencoding models for unsupervised anomaly segmentation in brain MR images,” *International MICCAI Brainlesion Workshop*, pp. 161-169, 2019.
- [6]X. Chen, E. Konukoglu, B. Glocker, and D. Rueckert, “Generative adversarial networks for multi-modality image registration,” *IEEE Transactions on Medical Imaging*, vol. 37, no. 1, pp. 134-146, 2018.
- [7]H. Salehinejad, S. Sankar, J. Barfett, E. Colak, and S. Valaee, “Recent advances in recurrent neural networks,” *arXiv preprint arXiv:1801.01078*, 2018.
- [8]J. Cheng, W. Huang, S. Cao, R. Yang, W. Yang, Z. Yun, et al., “Enhanced performance of brain tumor classification via tumor region augmentation and partition,” *PloS one*, vol. 10, no. 10, e0140381, 2016.

Link para acessar o código

<https://colab.research.google.com/drive/11SpxdvU369A1wWFN3UoW6HRfzADzdMdq?usp=sharing>.

Obrigado!